



Programa Certified AI-LLM Solution Architect

Fundamentos de Arquitectura LLM

Sesión 6 · Costos por Tokens/Latencia, Riesgos y Sesgos, y Selección de Alternativa

www.bsginstitute.com

Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 25 años de experiencia
- PGP Artificial Intelligence & Machine Learning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data – IEBSchool
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Especialista en MLOps de la Universidad de Duke
- Estudiante de Deep Learning for Healthcare Specialization
- Director de Inteligencia Artificial e Innovacion Universidad EAN/Colombia



anrojas@universidadean.edu.co / arojaspa@outlook.com / arojaspa76



@arojaspa



<https://www.linkedin.com/in/arojaspa/>



+573005906373



Costos por Tokens/Latencia, Riesgos y Sesgos, y Selección de Alternativa

Costo efectivo con percentiles de latencia, taxonomía y mitigación de sesgo con bias probe, y una matriz ponderada para elegir el proveedor base

Ubicación en el Curso

El Capítulo 3 arranca aquí, retomando las señales de calidad y faithfulness construidas en la Sesión 5 — el PoC ya sabe si responde bien y si es fiel al contexto.

Esta sesión agrega costo y latencia formal (percentiles, no promedios), gestión explícita de riesgo y sesgo, y cierra con una decisión final: qué proveedor usar, con una matriz ponderada y transparente.

PROGRESO DEL CURSO · 6 SESIONES

1

2

3

4

5

6

Agenda — Sesión 6

Tres bloques de trabajo · De la señal de calidad a la decisión de proveedor

01

60 min

Modelo de Costos por Tokens/Latencia

- ▶ Percentiles vs. promedio: P50, P95 y P99, nunca solo un número
- ▶ Del costo por token al costo efectivo, incorporando el SLA
- ▶ Cuatro bandas de interpretación de la tasa de incumplimiento
- ▶ Conexión con el costo por llamada ya visto en la Sesión 5

02

70 min

Riesgos y Sesgos: Principios de Mitigación

- ▶ Taxonomía de riesgo de Weidinger et al. (2021): 6 categorías
- ▶ Los tres momentos de mitigación: pre, en y post-procesamiento
- ▶ Bías probe: pares contrafactuales sobre Tienda Andina
- ▶ Cómo leer una alerta del bias probe sin sobreinterpretarla

03

50 min

Selección de Alternativa Base

- ▶ De cuatro señales (calidad, costo, latencia, riesgo) a una decisión
- ▶ AHP-Lite: normalizar antes de ponderar, sumar con pesos
- ▶ El proceso de selección en 4 pasos, con margen de confianza
- ▶ Demo guiada: eligiendo el proveedor base de Tienda Andina

Percentiles vs. Promedio: la Cola que Rompe la Experiencia

Tema 1 · De un número a una distribución: percentiles, no promedios

El Problema del Promedio

Un promedio de 800ms puede esconder que 1 de cada 20 llamadas tarda 6 segundos. La experiencia real del usuario está dominada por el peor caso, no por el caso típico — especialmente en sistemas con múltiples componentes de LLM encadenados, donde la cola de un paso se propaga a todo el pipeline.

La Solución: Percentiles

Reportar SIEMPRE P50 (mediana), P95 y P99 de la latencia — nunca solo un promedio. P50 describe la experiencia típica; P95 y P99 describen la experiencia de los usuarios más desafortunados, que en producción son suficientes para dañar la reputación del servicio.

Dean, J. & Barroso, L. A., 2013 — "The Tail at Scale", Communications of the ACM, 56(2), 74-80



Un proveedor con el promedio más bajo puede tener el peor P99 — por eso el modelo de costos de esta sesión exige reportar percentiles, no un solo número.

Del Costo por Token al Costo Efectivo

Tema 1 · Cuatro piezas que se combinan en un solo número de negocio

Componente	Qué mide
Costo por Llamada	Tokens × tarifa por millón — la fórmula de costeo ya vista en la Sesión 5.
Percentiles de Latencia	P50, P95 y P99 medidos sobre una muestra real de llamadas al proveedor.
Umbral de SLA	El tiempo máximo que el negocio tolera — lo define el equipo, no el proveedor.
Costo Efectivo	Combina las tres anteriores: ¿qué % de llamadas incumple el SLA, y qué tan grave es eso?

El costo por token nunca cuenta la historia completa: dos proveedores con la misma tarifa pueden tener un costo efectivo muy distinto si uno de ellos incumple el SLA con frecuencia.

 Implementado en modelo_costos.py — calcula costo por llamada, percentiles de latencia y la tasa de incumplimiento del SLA en una sola corrida.

Costo Efectivo: Cuatro Bandas de Interpretación

Tema 1 · Una fórmula simple, cuatro umbrales de acción

La Fórmula: Tasa de Incumplimiento

Proporción de llamadas que exceden el umbral de SLA definido por el equipo — la pieza que convierte latencia cruda en una señal de negocio, no solo en un número técnico.

$$\text{tasa} = \text{llamadas_excedidas} / \text{llamadas_totales}$$

→ un número entre 0% y 100%, calculado por proveedor

Las Cuatro Bandas de Interpretación

0% → el costo por token es la única variable relevante.

<5% → aceptable para la mayoría de casos de uso.

5-20% → evaluar si el caso de uso tolera esa variabilidad.

>20% → el costo por token puede ser engañoso

→ 1 de cada 5 respuestas rompe la experiencia del usuario

 La tasa de incumplimiento no reemplaza el costo por token: lo complementa. Un proveedor barato con tasa alta puede resultar más caro en la práctica.

 Implementado en `modelo_costos.py` — la banda de interpretación se calcula automáticamente a partir de la muestra de llamadas.

Taxonomía de Riesgo: 6 Categorías

Tema 2 · Seis categorías de daño para hablar con vocabulario común

01

Discriminación y Exclusión

02

Riesgos de Información

03

Desinformación

04

Usos Maliciosos

05

Interacción Humano-Máquina

06

Daños Ambientales/Socioeconómicos

Weidinger, L. et al., 2021 — [arXiv:2112.04359](#), DeepMind (también "Taxonomy of Risks posed by Language Models", ACM FAccT 2022)

Sesgo

→ Discriminación y Exclusión conecta con el bias probe de esta sesión (pares contrafactuales, más adelante en este tema).

OWASP

→ Riesgos de Información conecta con OWASP Top 10 for LLM Applications, ya visto en la Sesión 4.

RAGAS

→ Desinformación conecta con faithfulness/RAGAS (Es et al. 2023), ya visto en la Sesión 5.

Los Tres Momentos de Mitigación

Tema 2 · Gallegos et al. (2024) — dónde intervenir en el ciclo de vida del modelo

01 Pre-Procesamiento

Mitigar en los datos y el prompt, antes de la llamada: instrucciones explícitas de trato equitativo, prompts neutros que no sugieran atributos del cliente, curación del dataset de referencia.

```
prompt_neutro + instrucción_equidad
```

La mitigación más barata: se aplica antes de gastar en la llamada al modelo.

02 En-Procesamiento

Mitigar durante la generación: decodificación controlada, temperatura baja para reducir variabilidad no deseada, y restricciones de formato que limiten espacio para el sesgo.

```
temperature ↓ + decodificación controlada
```

Reduce variabilidad, pero no elimina el sesgo aprendido durante el entrenamiento.

03 Post-Procesamiento

Mitigar después de la respuesta: bias probe automatizado sobre pares contrafactuales, revisión humana de las alertas, y filtros que bloqueen patrones conocidos de trato diferencial.

```
bias_probe(par_A, par_B) → alerta /  
revisión
```

Implementado en riesgos_sesgos.py — la última línea de defensa antes de producción.

Bias Probe: la Técnica de Pares Contrafactuales

Gallegos et al. (2024) · riesgos_sesgos.py · dataset_sesgo.json — dominio Tienda Andina

El Método

Generar el mismo prompt cambiando solo un atributo del cliente — en este PoC, el nombre, que sugiere género u origen percibido — y comparar las respuestas del modelo.

Si hay diferencia sistemática de tono o longitud sin razón legítima relacionada con la tarea, es señal de trato diferencial — "counterfactual input pairs" (Gallegos et al., 2024).

Lo Que Mide Este PoC

6 pares de prompts sobre el dominio Tienda Andina: reembolsos, credibilidad de reclamos, tono general, urgencia percibida, ofertas, y explicaciones técnicas.

Comparados con una heurística de longitud + léxico de tono — barata y reproducible, no un análisis estadístico riguroso.

 Barato y reproducible no significa riguroso: el bias probe es una señal de post-procesamiento, no una auditoría estadística de sesgo.

Cómo Leer una Alerta del Bias Probe

Tema 2 · Cuatro reglas para no sobre-interpretar una señal heurística

1 · No es Prueba Confirmada

Una alerta NO es una prueba de sesgo confirmado — es una señal que exige revisión manual de ambas respuestas del par.

siempre revisión humana

2 · Diferencias Pueden Ser Legítimas

Diferencias de longitud pueden tener causas legítimas: una pregunta más compleja necesita más texto — revisar el contenido, no solo el número.

leer contenido, no solo métrica

3 · 0% No Significa "Sin Sesgo"

Una tasa de alerta de 0% no significa "sin sesgo" — significa que esta prueba heurística específica no lo detectó con los 6 pares evaluados.

4 · Solo Post-Procesamiento

El bias probe es una herramienta de post-procesamiento (ver el tema anterior) — no reemplaza la mitigación en pre- y en-procesamiento.

De Cuatro Señales a Una Decisión

Tema 3 · Cuatro números, un solo proveedor por elegir

Las Señales que Tenemos

Calidad (harness de evaluación, Sesión 5), costo (Sesión 5/6), latencia (P95 de este módulo) y riesgo de sesgo (tasa de alerta del bias probe de este módulo).

Por Qué Ninguna Basta Sola

El proveedor más barato puede tener la peor calidad; el de mejor calidad puede ser inviable en costo; el más rápido puede tener sesgo sin revisar — se necesita un método explícito para combinarlas.

Implementado en `seleccion_alternativa.py` — combina las cuatro señales en un método explícito.



Las cuatro señales apuntan en direcciones distintas casi siempre — la sección siguiente propone AHP-Lite, un método explícito para combinarlas.

AHP-Lite: Normalizar Antes de Ponderar

Tema 3 · Escalas distintas no se pueden combinar directamente

1 Por Qué Normalizar

USD, segundos y proporciones no son comparables directamente. Sin normalizar, el criterio con la escala numérica más grande domina el puntaje sin que sea la intención.

$$\text{valor_norm} = (\text{valor} - \text{min}) / (\text{max} - \text{min})$$

→ lleva cada criterio a una escala común 0-1

2 La Regla de Dirección

Calidad usa "mayor es mejor" (se normaliza tal cual). Costo, latencia y riesgo usan "menor es mejor" — se invierten para que las cuatro señales apunten en la misma dirección.

$$\text{invertido} = 1 - \text{valor_norm}$$


→ aplica a costo, latencia (P95) y riesgo (tasa de alerta)

 La fórmula final: $\text{puntaje_total} = \sum (\text{peso_criterio} \times \text{valor_normalizado_criterio})$, sumado sobre calidad, costo, latencia y riesgo.

 Versión simplificada del método de Saaty, T. L. (1980), "The Analytic Hierarchy Process (AHP) for Decision Making", McGraw-Hill.

El Proceso de Selección en 4 Pasos

Tema 3 · De señales sueltas a una recomendación con margen



Los cuatro pasos — Recolectar, Normalizar, Ponderar, Recomendar — se repiten cada vez que cambian los candidatos o las prioridades del negocio.

Versión simplificada del método de Saaty, T. L. (1980), "The Analytic Hierarchy Process (AHP) for Decision Making"

🔑 Si el margen entre el primer y segundo lugar es estrecho (<0.05 en escala 0-1), la recomendación debe decirlo explícitamente, no ocultarlo.

Cuándo Usar AHP-Lite vs. AHP Completo

Tema 3 · Saaty, T. L. (1980) — el rigor del original tiene un costo en tiempo


Escenario	AHP-Lite (este curso)	AHP Completo (Saaty original)
PoC rápido de bajo riesgo	✓ Recomendado — rápido, pesos subjetivos del equipo bastan.	X Innecesario — el tiempo de comparaciones pareadas no se justifica.
Stakeholders que no coinciden en prioridades	X Insuficiente — los pesos no se validan; el desacuerdo queda oculto.	✓ Recomendado — comparaciones por pares e índice de consistencia hacen el desacuerdo explícito.
Decisión de alto impacto/irreversible	X Insuficiente por sí solo — usar como primer filtro, no como decisión final.	✓ Recomendado — el rigor adicional se justifica por el costo de un error.
Presupuesto/tiempo limitado	✓ Recomendado — entrega un ranking defendible en minutos.	X Poco realista — toma mucho más tiempo recolectar y validar comparaciones.

En este curso usamos AHP-Lite por defecto: cubre el caso típico de un PoC. AHP Completo queda disponible como siguiente paso cuando el desacuerdo entre stakeholders o el costo de un error lo justifiquen.

🔑 La pregunta no es cuál método es "mejor" en abstracto, sino cuánto rigor exige esta decisión — y AHP-Lite es el punto de partida, no el techo.

Caso de Estudio: el Proveedor Base de Tienda Andina

Caso de estudio · Los tres temas de la sesión aplicados de punta a punta, en un solo pipeline



Stack Técnico

Backend FastAPI (Python) — orquesta costeo, bias probe y selección

Frontend React 18 + Vite 6 — dashboard del ranking de proveedores

Modelo local Ollama — para correr el bias probe sin costo de API

Guía Paso a paso local — ver session_6/GUIA_OLLAMA.md

El Código Vive en el Repo — No en Esta Diapositiva

- ▶ El pipeline completo — costos, riesgos y sesgos, y selección de alternativa — está implementado y documentado en el repo de la sesión.
- ▶ El objetivo de la clase es entender el marco de decisión, no transcribir código — el repo se recorre en la práctica guiada.
- ▶ Todos los archivos citados en esta sesión (modelo_costos.py, riesgos_sesgos.py, seleccion_alternativa.py, registro.py, dataset_sesgo.json) están en ese repo.

Síntesis: un Marco Integral

Cuatro preguntas antes de recomendar un proveedor

Costo

- ✓ El costo efectivo combina precio por token y confiabilidad — un proveedor barato pero inestable puede costar más en producción.
- ✓ `modelo_costos.py` combina costo por llamada con la banda de percentil (P50/P95/P99) en un solo número.

Latencia

- ✓ El promedio esconde la experiencia real del usuario — los percentiles (P50/P95/P99) revelan cuánto tarda la peor llamada de cada 20 o 100.

Riesgo-Sesgo

- ✓ La taxonomía de Weidinger et al. (2021) da vocabulario común a seis categorías de daño; el bias probe es una señal barata, no una prueba.
- ✓ Toda alerta de `riesgos_sesgos.py` exige revisión humana (Gallegos et al., 2024) — nunca es prueba confirmada por sí sola.

Selección

- ✓ Normalizar antes de ponderar (AHP-Lite, Saaty 1980): ninguna de las cuatro señales basta sola, y el margen entre candidatos siempre se reporta.



Resumen de la Sesión 6



Percentiles (P50/P95/P99) revelan lo que el promedio esconde.



La taxonomía de Weidinger et al. (2021) da vocabulario común a seis categorías de daño.



Ninguna señal sola basta: normalizar antes de ponderar (AHP-Lite, Saaty 1980).



Costo efectivo combina precio por token y confiabilidad, no solo tarifa.



Bias probe es señal barata que exige revisión humana — nunca prueba confirmada.



Reportar siempre el margen de confianza de la recomendación final.



Recursos del Curso

Perfil de costo/latencia → `modelo_costos.py`

Riesgos y sesgos → `riesgos_sesgos.py`

Selección de alternativa → `seleccion_alternativa.py`

Dataset de sesgo → `dataset_sesgo.json`

Registro y guía de pruebas local → `registro.py` · `GUIA_OLLAMA.md`